

Reporte del Laboratorio 2: Selección de Modelos y Regularización

Análisis del Dataset: Appliances Energy Prediction

Oscar Alfonso
of_alfonso@javeriana.edu.co

Kevin Bueno
bueno.kevin@javeriana.edu.co

26 de septiembre de 2026

1 Contexto de los Datos

El dataset utilizado se denomina *Appliances Energy Prediction* y proviene del *UCI Machine Learning Repository* (id 374) [2]. Contiene mediciones tomadas cada 10 minutos durante 4.5 meses (11 de enero al 27 de mayo de 2016) en una vivienda de bajo consumo en Bélgica. El objetivo es predecir el consumo energético de los electrodomésticos (**Appliances**, en Wh) a partir de sensores ambientales.

En los datos encontramos 19 735 observaciones y 28 predictores:

- **Sensores interiores:** temperatura (T1–T9) y humedad relativa (RH_1–RH_9) en nueve puntos de la vivienda.
- **Variables meteorológicas exteriores:** temperatura (T_out), humedad (RH_out), presión (Press_mm_hg), viento (Windspeed), visibilidad (Visibility) y punto de rocío (Tdewpoint).
- **Otros:** consumo de iluminación (lights) y dos variables aleatorias de control (rv1, rv2) introducidas por los autores del dataset.
- **Marca temporal:** date.

Los autores del dataset reportan que los modelos con mejor desempeño son de tipo ensamble (*gradient boosting*, *random forest*) [2], por lo que es esperable que las regresiones lineales alcancen un poder explicativo modesto. El énfasis de este laboratorio no es maximizar el desempeño sino aplicar y comparar las técnicas de selección de modelos y regularización descritas en [1]: *Best Subset Selection*, *Forward* y *Backward Stepwise Selection*, *Ridge*, *Lasso* y *Principal Components Regression* (PCR).

2 Exploración de Datos

2.1 Calidad de los datos

El dataset no presenta valores nulos ni filas duplicadas, y los 19 734 intervalos entre observaciones consecutivas son exactamente de 10 minutos, es decir, la serie temporal es continua. La columna **date** llega como cadena de texto sin separador entre fecha y hora (por ejemplo, 2016-01-1117:00:00), por lo que se parseó con un formato explícito. Adicionalmente se detectó que **rv1** y **rv2** son idénticas; se eliminó **rv2** y se conservó **rv1** como variable de control: al ser ruido aleatorio puro, un método de selección que funciona correctamente debería descartarla.

2.2 Variable objetivo

Tabla 1: Estadísticas descriptivas de la variable objetivo (**Appliances**, Wh)

Métrica	Appliances
count	19 735
mean	97.69
std	102.52
min	10
25%	50
50%	60
75%	100
max	1 080
asimetría (skew)	3.39

La variable objetivo presenta una fuerte asimetría positiva: la media (97.7) supera ampliamente a la mediana (60) y el 75% de las observaciones está por debajo de 100 Wh, mientras el máximo alcanza 1080 Wh. Además, los valores están discretizados en saltos de 10 Wh. Dado que la regresión lineal y sus variantes regularizadas asumen errores aproximadamente simétricos, se decidió modelar $\log(1 + \text{Appliances})$ (ver Figura 1).




Figura 1: Distribución de la variable objetivo en escala original (izquierda) y logarítmica (derecha). Los huecos en el histograma logarítmico reflejan la discretización en pasos de 10 Wh.

2.3 Escala de los predictores

Los predictores presentan escalas muy heterogéneas (Tabla 2). Como Ridge, Lasso y PCA son sensibles a la magnitud de las variables, todos los predictores se estandarizaron (media 0, desviación 1) ajustando el escalador únicamente con el conjunto de entrenamiento.

Tabla 2: Estadísticas descriptivas de predictores seleccionados (escalas heterogéneas)

Variable	mean	std	min	max
lights	3.80	7.94	0.00	70.00
T1	21.69	1.61	16.79	26.26
T6	7.91	6.09	−6.07	28.29
RH_6	54.61	31.15	1.00	99.90
T_out	7.41	5.32	−5.00	26.10
Press_mm_hg	755.52	7.40	729.30	772.30
RH_out	79.75	14.90	24.00	100.00
rv1	24.99	14.50	0.01	50.00

La variable **lights** toma el valor 0 en el 77% de las observaciones, por lo que se comporta casi como un indicador binario. Los sensores **T6** y **RH_6** corresponden a un punto exterior de la vivienda, lo que explica su rango distinto al del resto de sensores interiores.

2.4 Análisis de correlaciones

La matriz de correlación (Figura 2) muestra un patrón de “tablero de ajedrez”: todas las temperaturas están fuertemente correlacionadas entre sí, al igual que todas las humedades. Se trata de una misma vivienda medida en nueve puntos, lo que produce una multicolinealidad severa. Los pares con $|r| > 0.9$ se listan en la Tabla 3.




Figura 2: Matriz de correlación entre predictores y la variable objetivo transformada. La fila de **rv1** es blanca (correlación nula con todo), como corresponde a ruido aleatorio.

Tabla 3: Pares de predictores con correlación absoluta superior a 0.9

Variable 1	Variable 2	$ r $
T6	T_out	0.975
T7	T9	0.945
T5	T9	0.911
T3	T9	0.901

En contraste, la correlación lineal de los sensores con la variable objetivo es débil: el máximo corresponde a `lights` ($r = 0.26$) y ningún sensor de temperatura supera $r = 0.22$. Se decidió conservar todos los predictores colineales para observar cómo los trata cada método, en lugar de eliminarlos manualmente.

2.5 Ingeniería de variables temporales

Dado que el consumo de electrodomésticos depende de la rutina de los habitantes, se extrajo la hora del día y el día de la semana de la marca temporal (Figura 3). El consumo promedio es mínimo en la madrugada, sube a partir de las 7:00 y alcanza su pico a las 18:00. La hora del día, sin embargo, no debe usarse como entero: las 23:00 y las 0:00 están a una hora de distancia pero a 23 unidades numéricas. Por ello se codificó de forma cíclica:

$$\text{hour_sin} = \sin\left(\frac{2\pi h}{24}\right), \quad \text{hour_cos} = \cos\left(\frac{2\pi h}{24}\right). \quad (1)$$

Estas dos variables alcanzan correlaciones de -0.35 y -0.28 con el objetivo, superando a cualquier sensor. El día de la semana resultó irrelevante ($r = 0.02$; el rango de variación del panel derecho de la Figura 3 es de solo 0.17 en escala logarítmica), aunque se incluyó un indicador `is_weekend`. La matriz final contiene 29 predictores.




Figura 3: Consumo promedio (escala logarítmica) por hora del día y por día de la semana.

2.6 Partición temporal

Al tratarse de una serie temporal con observaciones vecinas casi idénticas, una partición aleatoria produciría fuga de información entre entrenamiento y prueba. Se utilizó una partición temporal: el primer 80% de la serie (11 de enero al 30 de abril, 15 788 filas) para entrenar y el 20% restante (30 de abril al 27 de mayo, 3 947 filas) para probar. Todos los hiperparámetros (k , α , M) se seleccionaron mediante validación cruzada temporal (`TimeSeriesSplit` con 5 particiones) usando únicamente el conjunto de entrenamiento.

3 Metodología y Análisis de Resultados

3.1 Modelo de referencia

Se ajustó una regresión lineal múltiple con los 29 predictores estandarizados:

$$\log(\widehat{1+y}) = \beta_0 + \sum_{j=1}^{29} \beta_j X_j. \quad (2)$$

Se obtuvo $R^2 = 0.346$ en entrenamiento y $R^2 = 0.229$ en prueba. La brecha entre ambos refleja un sobreajuste leve y, sobre todo, un cambio de régimen: el modelo se entrena con invierno e inicios de primavera y se evalúa en mayo, con temperaturas fuera del rango observado.

3.2 Best Subset Selection

Con 29 predictores el espacio completo tiene $2^{29} \approx 5.4 \times 10^8$ subconjuntos, lo que resulta computacionalmente inviable. Se limitó la búsqueda exhaustiva a subconjuntos de tamaño $k \leq 4$ (27840 modelos), seleccionando dentro de cada tamaño el subconjunto con mayor R^2 de validación cruzada temporal.

Tabla 4: Best Subset Selection: mejor subconjunto por tamaño k

k	Predictores	R^2 CV	R^2 test
1	hour_sin	0.111	0.067
2	hour_sin, hour_cos	0.194	0.179
3	T3, hour_sin, hour_cos	0.244	0.039
4	T3, T6, hour_sin, hour_cos	0.257	0.147

Dos observaciones destacan. Primero, las variables construidas en el EDA (`hour_sin` y `hour_cos`) son las dos primeras seleccionadas entre 29 candidatas. Segundo, el criterio de validación cruzada sigue mejorando al incluir T3, pero el R^2 de prueba se desploma de 0.179 a 0.039. Para entender este fenómeno se ajustó el modelo con $k = 4$ mediante `statsmodels` (Tabla 5) y se comparó la distribución de T3 en entrenamiento y prueba (Tabla 6).

Tabla 5: Coeficientes del mejor modelo con $k = 4$ (predictores estandarizados)

Variable	coef	std err	t	$P > t $
const	4.3073	0.004	957.8	0.000
lights	0.1569	0.005	33.9	0.000
T3	0.1312	0.005	29.0	0.000
hour_sin	-0.1940	0.005	-41.8	0.000
hour_cos	-0.1878	0.005	-41.7	0.000

Tabla 6: Distribución de T3 (°C) en entrenamiento y prueba

Métrica	train	test
mean	21.59	24.98
std	1.50	1.39
25%	20.50	24.10
50%	21.63	24.86
75%	22.60	26.17

T3 es altamente significativa en entrenamiento ($t = 29$, $p < 0.001$), pero el percentil 25 de T3 en prueba (24.1) supera al percentil 75 en entrenamiento (22.6): tres cuartas partes de las observaciones de mayo caen en una región que el modelo apenas vio. La relación “mayor temperatura, mayor consumo” aprendida en invierno no se sostiene en mayo. Ni el BIC, ni la validación cruzada temporal, ni la significancia estadística detectan este problema, porque los tres evalúan dentro del rango de los datos de entrenamiento.

3.3 Forward y Backward Stepwise Selection

Se aplicaron ambos procedimientos codiciosos sobre los 29 predictores usando `mlxtend`, con el R^2 de validación cruzada temporal como criterio en cada paso (Figura 4).




Figura 4: R^2 de validación cruzada temporal y de prueba en función del número de predictores. La línea punteada marca el k óptimo según validación cruzada.

Forward. Los primeros cuatro pasos coinciden exactamente con los ganadores de Best Subset, de modo que la heurística codiciosa no perdió calidad respecto a la búsqueda exhaustiva. El R^2 de CV alcanza su máximo (0.274) en $k = 8$ con el conjunto {RH_1, T3, T5, T6, RH_9, Windspeed, hour_sin, hour_cos}. La variable de control **rv1** ingresa en $k = 9$, es decir, inmediatamente después de agotarse la señal útil. El R^2 de prueba del modelo óptimo es 0.161.

Backward. La primera variable eliminada es **rv1**. El máximo de CV (0.281) ocurre en $k = 13$ con un conjunto distinto al de Forward, lo que ilustra que con predictores intercambiables la selección no es única. El R^2 de prueba es 0.172.

Un detalle relevante en la curva de Forward: el R^2 de prueba salta de 0.166 a 0.239 en $k = 18$, cuando ingresa T9, variable con correlaciones superiores a 0.9 con T3, T5 y T7. Sola aporta poco, pero en conjunto con sus pares permite al modelo aprender *diferencias* entre habitaciones, que son mucho más estables entre estaciones que las temperaturas absolutas. La multicolinealidad actúa aquí como amortiguador frente al cambio de régimen.

3.4 Ridge Regression

Ridge minimiza $RSS + \alpha \sum_j \beta_j^2$, encogiendo todos los coeficientes sin anularlos. El valor $\alpha = 1215$ se seleccionó por validación cruzada temporal sobre una malla logarítmica de 60 valores. El modelo alcanza $R^2 = 0.332$ en entrenamiento y $R^2 = 0.242$ en prueba, siendo el único método que supera al modelo de referencia.




Figura 5: Trayectoria de los coeficientes de Ridge en función de α . En naranja, `hour_sin`, `hour_cos` y `rv1`; la línea punteada marca el α óptimo.

En la Figura 5 se observa que los pares colineales (`T6/T_out`, `T7/T9`) reciben en OLS coeficientes grandes de signo opuesto que se cancelan mutuamente, firma clásica de la multicolinealidad; Ridge los aplasta a partir de $\alpha \approx 100$. Las variables horarias son las últimas en encogerse, y `rv1` permanece pegada a cero en todo el recorrido.

3.5 Lasso Regression

Lasso minimiza $RSS + \alpha \sum_j |\beta_j|$, lo que produce coeficientes exactamente nulos y por tanto selección automática de variables. Con $\alpha = 0.012$ (validación cruzada temporal), el modelo conserva 17 de los 29 predictores (Tabla 7) y anula `rv1`. Obtiene $R^2 = 0.315$ en entrenamiento y $R^2 = 0.213$ en prueba.

Tabla 7: Coeficientes no nulos de Lasso, ordenados por magnitud

Variable	coef	Variable	coef
hour_cos	-0.200	RH_7	-0.022
hour_sin	-0.161	RH_8	-0.020
T3	0.141	T4	-0.011
lights	0.135	RH_5	0.010
T8	0.086	is_weekend	0.008
T9	-0.072	Press_mm_hg	-0.006
RH_1	0.038	T_out	-0.002
RH_3	0.034		
RH_9	-0.031		
T6	-0.030		




Figura 6: Trayectoria de los coeficientes de Lasso. Leída de derecha a izquierda, el orden de ingreso es `hour_sin`, `hour_cos`, `T3`, `lights`: el mismo que encontraron Best Subset y Forward.

Lasso pierde frente al modelo de referencia por la misma razón que los métodos Stepwise: elimina precisamente los sensores redundantes (`T5`, `T7`, `T_out`) que estabilizan la extrapolación, mientras conserva `T3` con un coeficiente elevado.

3.6 Análisis de Componentes Principales y PCR

PCA construye combinaciones lineales de los predictores ordenadas por varianza explicada. Se requieren 8, 12 y 15 componentes para explicar el 80%, 90% y 95% de la varianza (Figura 7), confirmando la redundancia entre sensores. Sobre estas componentes se ajustó una regresión lineal (PCR), eligiendo el número de componentes M por validación cruzada temporal (Figura 8).




Figura 7: Varianza explicada acumulada por componente principal.




Figura 8: R^2 de validación cruzada temporal de PCR en función de M .

El resultado más ilustrativo es que las tres primeras componentes, que explican el 61% de la varianza de los predictores, tienen un R^2 de CV prácticamente nulo. Los saltos en $M = 4$ y $M = 12$ corresponden al ingreso de las componentes que cargan sobre `hour_sin` y `hour_cos`. PCA es no supervisado: maximiza la varianza de X sin mirar y , y la varianza dominante vive en los sensores redundantes mientras la señal predictiva vive en dos columnas de baja varianza compartida. Se requirieron $M = 17$ componentes para alcanzar $R^2 = 0.227$ en prueba, sin mejora respecto a la regresión con los 29 predictores originales.

4 Comparación de Modelos

Tabla 8: Comparación de los modelos ajustados (partición temporal, objetivo $\log(1 + y)$)

Modelo	Predictores	R^2 train	R^2 test	RMSE test
Ridge ($\alpha = 1215$)	29	0.332	0.242	0.487
OLS (todos los predictores)	29	0.346	0.229	0.491
PCR ($M = 17$)	17	0.310	0.227	0.491
Lasso ($\alpha = 0.012$)	17	0.315	0.213	0.496
Best Subset ($k = 2$)	2	0.200	0.179	0.506
Backward Stepwise ($k = 13$)	13	0.304	0.172	0.508
Best Subset ($k = 3$)	3	0.248	0.163	0.511
Forward Stepwise ($k = 8$)	8	0.265	0.161	0.512
Best Subset ($k = 4$)	4	0.286	0.081	0.536
Best Subset ($k = 1$)	1	0.130	0.067	0.540

La Tabla 8 muestra un gradiente claro: los métodos que conservan todos los predictores (Ridge, OLS, PCR) ocupan los primeros lugares; Lasso, que elimina con moderación, queda en el medio; y los métodos de selección agresiva (Best Subset, Stepwise) ocupan los últimos. Cuantas más variables se eliminan, peor es la extrapolación a mayo.

5 Conclusiones

1. Ridge es el único método que supera al modelo de referencia en prueba ($R^2 = 0.242$ frente a 0.229). Encoger los coeficientes sin eliminar predictores resulta la estrategia adecuada cuando los predictores redundantes amortiguan un cambio de distribución.
2. Todos los métodos que eliminan variables (Best Subset, Forward, Backward, Lasso) mejoran el R^2 de validación cruzada pero empeoran el de prueba respecto a la referencia. Los

sensores colineales que descartan son los que estabilizan la extrapolación a un periodo más cálido.

3. Ningún criterio in-sample (BIC, validación cruzada temporal, significancia estadística) detectó que T3 extrapola mal. La validación cruzada protege contra el sobreajuste al ruido, pero no contra un futuro cuya distribución difiere del pasado.
4. La señal más robusta es la hora del día, construida en el EDA mediante codificación cíclica. Cuatro algoritmos independientes (Best Subset, Forward, Backward y Lasso) la seleccionaron en primer lugar entre 29 candidatas.
5. La variable de control `rv1` fue descartada por los seis métodos: Lasso la anuló, Backward la eliminó primero, Forward la incorporó solo tras agotar la señal útil, y Ridge la mantuvo pegada a cero.
6. PCR no aporta mejoras: la varianza dominante de los predictores corresponde a sensores redundantes, mientras la señal predictiva reside en direcciones de baja varianza.
7. Limitaciones: Best Subset se truncó en $k \leq 4$ por costo computacional, y el R^2 absoluto es bajo en todos los casos porque el consumo depende de comportamientos de los habitantes que los sensores no capturan, en línea con lo reportado en [2].

A Código fuente

El código completo del laboratorio (carga de datos, EDA, ingeniería de variables, los seis métodos y la tabla comparativa) se encuentra en el notebook `notebooks/lab02.ipynb` del siguiente repositorio:

<https://github.com/aristotekean/ml-lab02-best-subset-lasso>

Referencias

- [1] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). *An Introduction to Statistical Learning: with Applications in R* (2nd ed.). Springer. <https://www.statlearning.com/>
- [2] Candanedo, L. M., Feldheim, V., & Deramaix, D. (2017). Data driven prediction models of energy use of appliances in a low-energy house. *Energy and Buildings*, 140, 81–97.